

---

# Применение машинного обучения в 5G. Нейросетевой приёмник и его СВАМ модификация.

---

A Preprint

Овсиенко О. П.

МГУ им. М.В. Ломоносова

факультет ВМК

119991, Москва, Ленинские горы, д.1, стр. 52

st02220041@gse.cs.msu.ru

Бобров Е. А.

МГУ им. М.В. Ломоносова

факультет ВМК

119991, Москва, Ленинские горы, д.1, стр. 52

## Abstract

В статье исследуется применении методов машинного и глубокого обучения для оптимизации физического уровня (англ. PHY Layer) в современных системах мобильной связи пятого поколения (англ. 5G). Рассмотрены традиционные методы обработки сигналов, такие как линейная эквализация (англ. LMMSE equalizer) и оценка канала методом наименьших квадратов (англ. LS channel estimator), а также нейросетевые подходы, включая архитектуру с остаточными блоками от NVIDIA. Центральным результатом работы стала разработка модификации нейросетевого приёмника с модулем внимания свёрточного блока (англ. Convolutional Block Attention Module, СВАМ), которая продемонстрировала превосходство над классическими методами в условиях многолучевого распространения и помех. Практическая значимость исследования заключается в возможности интеграции предложенного метода в современные системы связи для повышения их эффективности и устойчивости к помехам.

Keywords традиционные методы обработки сигналов · нейросетевой приёмник

## 1 Введение

Современные системы мобильной связи пятого поколения сталкиваются с необходимостью обеспечения исключительно высокой скорости передачи данных, сверхнизких задержек и надёжного соединения для миллионов устройств. Эти требования предъявляют новые вызовы к методам обработки сигналов на PHY Layer, особенно в условиях многолучевого распространения и интерференции. Традиционные алгоритмы, такие как LS channel estimator и LMMSE equalizer ([Badr et al. \[2019\]](#)), зачастую не справляются с растущей сложностью каналов, что стимулирует поиск более совершенных и адаптивных подходов.

Классические подходы к обработке сигналов в системах связи с несколькими входами и несколькими выходами (англ. MIMO) в сочетании с технологией мультиплексирования с ортогональным разделением частот (англ. OFDM) ([Bagadi and Das \[2010\]](#)), такие как оценка канала на основе пилот-сигналов и последующий LMMSE equalizer, хорошо изучены и обеспечивают приемлемое качество в условиях

умеренных помех. Однако их эффективность существенно снижается в сценариях с сильной интерференцией, быстрыми замираниями и в отсутствие точной информации о состоянии канала (англ. Channel State Information, CSI). LS channel estimator, будучи вычислительно простым, крайне чувствителен к шуму, в то время как более робастные методы, такие как LMMSE equalizer, требуют априорного знания статистики канала и шума, что зачастую недостижимо в реальных динамичных условиях.

В последние годы активно развиваются методы машинного и глубокого обучения, демонстрирующие значительный потенциал для оптимизации телекоммуникационных систем. В частности, нейросетевые приёмники, способные обучаться сквозному преобразованию принятого сигнала в битовые последовательности, показывают результаты, превосходящие классические методы. Одной из таких современных архитектур является нейросетевой приёмник от NVIDIA ([Hoydis et al.]), построенный на основе остаточных свёрточных блоков (англ. Residual Blocks), который позволяет эффективно компенсировать искажения сигнала без явного знания матрицы канала.

В данной работе предлагается модификация данного нейросетевого приёмника, направленная на дальнейшее повышение его эффективности. Модификация заключается во внедрении механизма внимания СВАМ (Woo et al. [2018]) в структуру остаточных блоков. Этот механизм позволяет сети адаптивно выделять наиболее информативные признаки в частотно-временном и канальном пространствах, усиливая полезные компоненты сигнала и подавляя шумовые.

Экспериментальные исследования, проведённые на кластеризованных каналах линии задержки (англ. Clustered Delay Line Channel, CDL), подтвердили эффективность предложенного подхода (Pessoa et al. [2020]). Модифицированный приёмник продемонстрировал устойчивое улучшение показателя частоты ошибочных блоков (англ. Block Error Rate, BLER) по сравнению как с классическими методами (LS channel estimator, LMMSE equalizer), так и с базовой нейросетевой архитектурой, в особенности в условиях нелинейной видимости (англ. NLOS) и при низких отношениях сигнал/шум. Таким образом, вклад работы заключается в разработке и валидации усовершенствованной архитектуры приёмника, что открывает пути для создания более помехоустойчивых и спектрально-эффективных систем связи следующего поколения.

## 2 Обзор литературы

Современные системы связи пятого поколения требуют принципиально новых подходов к обработке сигналов на физическом уровне. Традиционные методы, такие как оценка канала и эквалайзация, хорошо изучены, но имеют существенные ограничения в условиях сложных сценариев распространения сигнала. Badr et al. [2019] проводит всесторонний анализ LMMSE equalizer оценки канала в контексте OFDM систем, подчеркивая её преимущества перед более простыми методами, такими как LS channel estimator, но также отмечая зависимость от точного знания статистических характеристик канала. Исследование Bagadi and Das [2010] демонстрирует применение пилот-сигналов для оценки канала в системах MIMO-OFDM, что является стандартным подходом в современных системах связи.

Архитектуры MIMO систем играют ключевую роль в повышении пропускной способности и надежности беспроводных каналов. Shah [2017] предоставляет сравнительный анализ различных конфигураций MIMO, включая системы с одним входом и одним выходом (англ. SISO), с одним входом и несколькими выходами (англ. SIMO), с несколькими входами и одним выходом (англ. MISO) и MIMO, показывая преимущества пространственного разнесения и мультиплексирования. Дальнейшее развитие MIMO технологий представлено в работе Pessoa et al. [2020], где предлагается модель канала на основе CDL с двухполяризованными антеннами, специально адаптированная для сценариев 5G в сельской местности.

Теоретические основы достижимых скоростей передачи в системах связи продолжают развиваться. Björnson et al. [2015] исследует предельные возможности Rician MIMO каналов с учетом аппаратных искажений, что особенно актуально для систем массового MIMO. В то же время Caire et al. [2017] фокусируется на методах вероятностного формирования сигналов (probabilistic shaping) для повышения спектральной эффективности.

Прорыв в области глубокого обучения открыл новые перспективы для оптимизации физического уровня. Архитектура глубоких остаточных свёрточных сетей, представленная в работе He et al. [2016], стала фундаментом для многих последующих разработок, включая нейросетевые приемники. Механизмы внимания, такие как СВАМ из исследования Woo et al. [2018], демонстрируют эффективность в выделении информативных признаков в компьютерном зрении, что может быть успешно перенесено на задачи обработки сигналов.

Современные инструменты для исследований в области связи, такие как Sionna от NVIDIA [Hoydis et al.], предоставляют мощную платформу для сквозного моделирования систем связи и интеграции методов машинного обучения. В частности, Hoydis et al. [2023] демонстрирует применение нейросетевых приемников для OFDM SIMO систем. Исследования Levis et al. [2020a] и Levis et al. [2020b] развивают концепцию полностью сверточного глубокого приемника и сквозного обучения для OFDM систем, включая возможность беспилотной коммуникации.

Важным аспектом современных систем связи являются эффективные методы кодирования. Работы Nguyen et al. [2019] и Nguyen et al. [2021] посвящены разработке низкосложных декодеров QC-LDPC для 5G, что критически важно для практической реализации систем следующего поколения. Перспективным направлением является также совместное демодулирование сложных созвездий с использованием машинного обучения, как показано в исследовании Gansekoele et al. [2025].

Таким образом, современное состояние исследований демонстрирует четкий тренд к интеграции методов машинного обучения с классическими подходами обработки сигналов, что открывает новые возможности для создания более эффективных и устойчивых систем связи.

### 3 Математическая постановка задачи

Рассматривается система MIMO с  $N_t$  передающими антеннами и  $N_r$  принимающими антеннами. Пусть:

$$\mathbf{x} = \mathbf{W}\mathbf{s} \quad (1)$$

где  $\mathbf{W} \in \mathbb{C}^{N_t \times N_r}$  – матрица преодолера,  $\mathbf{s} \in \mathbb{C}^{N_r \times 1}$  – вектор исходных сигналов ( бинарная последовательность ), а  $\mathbf{x} \in \mathbb{C}^{N_t \times 1}$  - передаваемый вектор сигналов после преодолера ( каждый символ в пропорции распространён по всем антеннам ). Этот вектор обычно берётся из некоторой M-QAM/QPSK сигнальной диаграммы, т. е.  $\mathbf{x}$  состоит из комплексных значений, отражающих точку созвездия.

Модель прохождения сигнала через канал можно записать в следующем виде:

$$\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{n}, \quad (2)$$

где

$$\mathbf{y} \in \mathbb{C}^{N_r \times 1}$$

– вектор принятых сигналов на антенных элементах приёмника,  $\mathbf{H} \in \mathbb{C}^{N_r \times N_t}$  – матрица канала, описывающая затухание и фазовые сдвиги на пути «от каждой передающей антенны к каждой приёмной», а  $\mathbf{n} \in \mathbb{C}^{N_r \times 1}$  – вектор аддитивного белого гауссовского шума (AWGN) с дисперсией  $\sigma_n^2$ .

В классической постановке задачи МИМО-декодирования (или «символьной детекции») требуется найти оценки  $\hat{\mathbf{x}}$  переданных символов, обладающие минимальной вероятностью ошибки. При стандартном подходе (например, методе MMSE – Minimum Mean Square Error) оценивается:

$$\hat{\mathbf{x}}_{\text{MMSE}} = \underset{\mathbf{x}}{\operatorname{argmin}}(\|\mathbf{y} - \mathbf{Hx}\|^2 + \sigma_n^2 \|\mathbf{x}\|^2). \quad (3)$$

Для высоких размерностей (большое число антенн  $N_t$  и  $N_r$ ), а также для сложных созвездий (например, 64-QAM, 256-QAM) точный поиск  $\mathbf{x}$  может становиться вычислительно дорогостоящим. Методы глубокого обучения позволяют решать данную задачу итеративно или напрямую, обучаясь на большом наборе «принятый сигнал – истинный символ» без явной оптимизации по формуле минимума ошибки.

В рамках предлагаемой работы рассматривается ситуация, когда матрица канала  $\mathbf{H}$  частично неизвестна или может изменяться со временем, а число передатчиков и приёмников велико. Требуется реализовать «глубокую» нейронную сеть, которая сможет, во-первых, оценивать параметры  $\mathbf{H}$  по пилотным символам, а во-вторых, автоматически восстанавливать  $\mathbf{x}$  из  $\mathbf{y}$  с учётом сложности канала и помех.

Основная цель формализуется как задача:

$$\hat{\mathbf{x}} = \mathcal{F}_\theta(\mathbf{y}, \mathbf{p}), \quad (4)$$

где  $\mathbf{p}$  – набор пилотных символов, а  $\mathcal{F}_\theta$  – функция, задаваемая параметрами нейронной сети  $\theta$ .

Требуется найти такие параметры  $\theta$ , которые минимизируют среднюю вероятность ошибки детектирования:

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \mathbb{E}_{(\mathbf{x}, \mathbf{H}, \mathbf{n})} \left\{ \ell(\mathcal{F}_\theta(\mathbf{y}, \mathbf{p}), \mathbf{x}) \right\}, \quad (5)$$

где  $\ell(\cdot)$  – функция потерь (кросс-энтропия).

Для оценки качества декодирования в моделях связи используются BLER и  $\frac{E_b}{N_0}$ :

$$\text{BLER} = \frac{\text{Количество ошибочно переданных блоков}}{\text{Общее количество переданных блоков}}, \quad (6)$$

$$\frac{E_b}{N_0} = \frac{\text{Энергия на один бит}}{\text{Спектральная плотность мощности шума}} [\text{дБ}] \quad (7)$$

Ошибочный блок – это блок, в котором хотя бы один бит не совпадает с исходным. BLER помогает отслеживать эффективность модели, показывая, насколько часто возникают ошибки в передаваемых данных. Чем ниже BLER, тем лучше модель справляется с исправлением ошибок.

## 4 Предложенный метод

Модификация, которая была применена к нейросетевому приёмнику, основана на статье "СВАМ: Convolutional Block Attention Module"(Woo et al. [2018]) и направлена на улучшение работы модели за счет добавления механизма внимания.

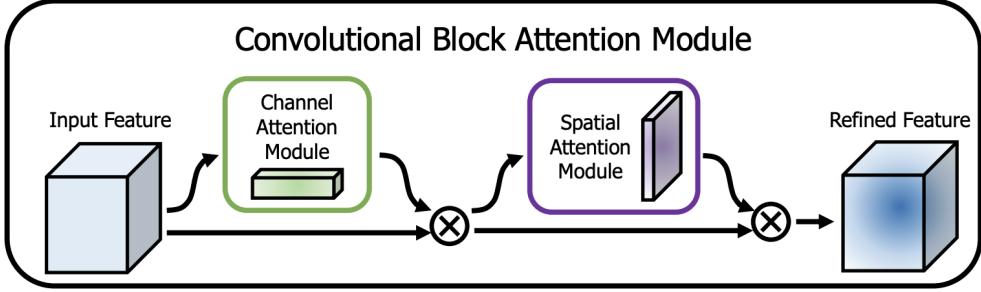


Рис. 1: Схема архитектуры СВАМ модуля

#### 4.1 Исходный нейросетевой приёмник

Исходный нейросетевой приёмник можно описать как композицию последовательных преобразований. Пусть входные данные  $\mathbf{Y} \in \mathbb{C}^{B \times N_r \times N_s \times N_c}$ , где  $B$  – размер батча,  $N_r$  – количество приёмных антенн,  $N_s$  – количество OFDM-символов,  $N_c$  – количество поднесущих.

Преобразование входных данных в вещественноненаправленный тензор:

$$\mathbf{Z}_0 = \text{Conv2D}(\text{concat}[\Re(\mathbf{Y}^T), \Im(\mathbf{Y}^T), \mathbf{N}_0]) \quad (8)$$

где  $\mathbf{Y}^T$  – транспонированная версия  $\mathbf{Y}$  с размещением размерности антенн последней,  $\Re(\cdot)$  и  $\Im(\cdot)$  – операторы взятия действительной и мнимой части комплексного числа соответственно,  $\mathbf{N}_0 = \log_{10}(\mathbf{n}_0) \otimes \mathbf{1}_{N_s \times N_c}$  – расширенный тензор дисперсии шума.

Далее применяется последовательность остаточных блоков:

$$\mathbf{Z}_l = \mathcal{R}_l(\mathbf{Z}_{l-1}) + \mathbf{Z}_{l-1}, \quad l = 1, \dots, 4 \quad (9)$$

где  $\mathcal{R}_l$  –  $l$ -й остаточный блок, определяемый как:

$$\mathbf{Z}_l^{(1)} = \text{ReLU}(\text{LayerNorm}(\mathbf{Z}_{l-1})) \quad (10)$$

$$\mathbf{Z}_l^{(2)} = \text{Conv2D}(\mathbf{Z}_l^{(1)}) \quad (11)$$

$$\mathbf{Z}_l^{(3)} = \text{ReLU}(\text{LayerNorm}(\mathbf{Z}_l^{(2)})) \quad (12)$$

$$\mathbf{Z}_l^{(4)} = \text{Conv2D}(\mathbf{Z}_l^{(3)}) \quad (13)$$

$$\mathcal{R}_l(\mathbf{Z}_{l-1}) = \mathbf{Z}_l^{(4)} \quad (14)$$

Итоговые логарифмические отношения правдоподобия (англ. LLR) вычисляются как:

$$\mathbf{LLR} = \text{Conv2D}(\mathbf{Z}_4) \quad (15)$$

#### 4.2 Модификация с механизмом внимания CBAM

Модификация заключается в замене стандартных остаточных блоков  $\mathcal{R}_l$  на блоки с двойным механизмом внимания CBAM. Новый остаточный блок  $\mathcal{R}_l^{CBAM}$  определяется как:

$$\mathbf{Z}_l^{(1)} = \text{ReLU}(\text{LayerNorm}(\mathbf{Z}_{l-1})) \quad (16)$$

$$\mathbf{Z}_l^{(2)} = \text{Conv2D}(\mathbf{Z}_l^{(1)}) \quad (17)$$

$$\mathbf{Z}_l^{(3)} = \text{ReLU}(\text{LayerNorm}(\mathbf{Z}_l^{(2)})) \quad (18)$$

$$\mathbf{Z}_l^{(4)} = \text{Conv2D}(\mathbf{Z}_l^{(3)}) \quad (19)$$

$$\mathbf{Z}_l^{(5)} = \mathcal{C}(\mathbf{Z}_l^{(4)}) \quad (\text{канальное внимание}) \quad (20)$$

$$\mathbf{Z}_l^{(6)} = \mathcal{S}(\mathbf{Z}_l^{(5)}) \quad (\text{пространственное внимание}) \quad (21)$$

$$\mathcal{R}_l^{CBAM}(\mathbf{Z}_{l-1}) = \mathbf{Z}_l^{(6)} \quad (22)$$

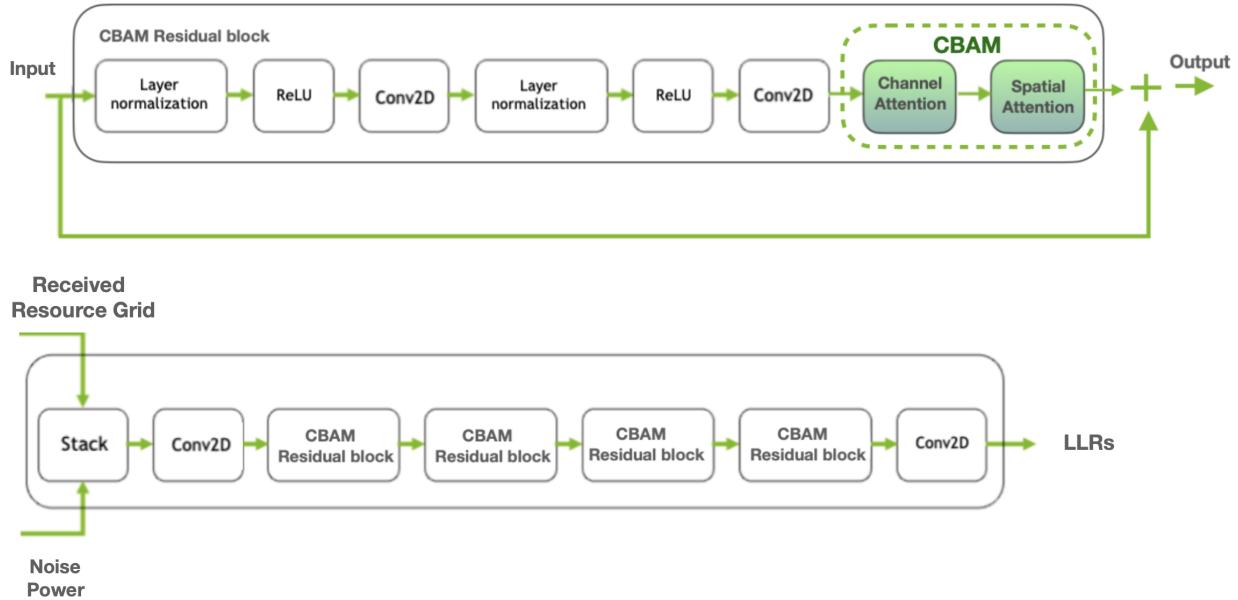


Рис. 2: Схема модифицированного нейросетевого приёмника

#### 4.2.1 Канальное внимание $\mathcal{C}$

Канальное внимание вычисляет веса для каждого канала признакового пространства:

$$\mathbf{A}_{avg} = \text{MLP} \left( \frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W \mathbf{Z}[:, i, j, :] \right) \quad (23)$$

$$\mathbf{A}_{max} = \text{MLP} \left( \max_{i,j} \mathbf{Z}[:, i, j, :] \right) \quad (24)$$

$$\mathcal{C}(\mathbf{Z}) = \mathbf{Z} \otimes \sigma(\mathbf{A}_{avg} + \mathbf{A}_{max}) \quad (25)$$

где  $\sigma$  – сигмоидная функция активации,  $\otimes$  – поэлементное умножение с broadcast по пространственным измерениям, MLP – двухслойный перцептрон со скрытым слоем размерности  $C/r$ .

#### 4.2.2 Пространственное внимание $\mathcal{S}$

Пространственное внимание вычисляет веса для каждой пространственной позиции:

$$\mathbf{S}_{avg} = \text{mean}_{channel}(\mathbf{Z}) \quad (26)$$

$$\mathbf{S}_{max} = \text{max}_{channel}(\mathbf{Z}) \quad (27)$$

$$\mathcal{S}(\mathbf{Z}) = \mathbf{Z} \otimes \text{Conv2D}_{7 \times 7}(\text{concat}[\mathbf{S}_{avg}, \mathbf{S}_{max}]) \quad (28)$$

где свертка с ядром  $7 \times 7$  имеет один выходной канал и сигмоидную активацию.

#### 4.3 Итоговый модифицированный приёмник

Модифицированный нейросетевой приёмник описывается следующими преобразованиями:

$$\mathbf{Z}_0 = \text{Conv2D}(\text{concat}[\Re(\mathbf{Y}^T), \Im(\mathbf{Y}^T), \mathbf{N}_0]) \quad (29)$$

$$\mathbf{Z}_l = \mathcal{R}_l^{CBAM}(\mathbf{Z}_{l-1}) + \mathbf{Z}_{l-1}, \quad l = 1, \dots, 4 \quad (30)$$

$$\mathbf{LLR} = \text{Conv2D}(\mathbf{Z}_4) \quad (31)$$

где  $\mathcal{R}_l^{CBAM}$  – остаточные блоки с механизмом СВАМ, последовательно применяющие канальное и пространственное внимание для адаптивного уточнения признакового пространства.

### 5 Эксперименты

#### 5.1 Описание методов

1. Perfect CSI приёмник: Является теоретическим эталоном. Предполагает, что приёмнику точно известна матрица канала, что позволяет LMMSE equalizer оптимально компенсировать искажения. В реальных условиях не реализуем, но задаёт верхнюю границу производительности.
2. LS estimation приёмник: Реалистичный подход, в котором для оценки канала используются пилот-символы и LS channel estimator. Оценки с пилотов интерполируются на все поднесущие. Метод прост в реализации, но чувствителен к шуму, особенно в условиях низкого отношения сигнал/шум (англ. SNR), что ухудшает качество эквализации.
3. Нейросетевой приёмник (англ. Neural Receiver) от NVIDIA: Использует сквозную архитектуру на основе свёрточной нейросети с остаточными блоками, которых 4 или 6. Приёмник напрямую преобразует принятую OFDM-решётку в LLR, минуя явные этапы оценки канала и эквализации. Обучен адаптироваться к характеристикам канала, но требует предварительного обучения под конкретные условия.
4. Нейросетевой приёмник с CBAM Residual Blocks: Модифицированная версия нейросетевого приёмника, в которой стандартные остаточные блоки заменены на блоки с механизмом двойного внимания СВАМ. Данная архитектура позволяет сети адаптивно выделять наиболее информативные каналы и пространственные области признакового пространства, улучшая качество детектирования за счет подавления шумовых компонент и усиления значимых признаков. Сохраняет преимущества сквозного подхода, но обладает повышенной способностью к фильтрации помех.

## 5.2 Сравнение результатов

Channel	BLER	Neural Receiver with 4 Residual Blocks (dB)	Neural Receiver with 6 Residual Blocks (dB)	Neural Receiver with 4 CBAM Residual Blocks (dB)
A	$10^{-1}$	0.345	0.276	0.207 0.241
	$10^{-2}$	0.483	0.345	
B	$10^{-1}$	0.492	0.431	0.308 0.431
	$10^{-2}$	0.799	0.738	
C	$10^{-1}$	0.345	0.345	0.276 0.276
	$10^{-2}$	0.345	0.414	
D	$10^{-1}$	0.207	0.345	0.172 0.207
	$10^{-2}$	0.310	0.621	
E	$10^{-1}$	0.207	0.414	0.138 0.138
	$10^{-2}$	0.241	0.621	

Таблица 1: Детальное сравнение эффективности различных архитектур нейросетевых приёмников относительно эталонного приёмника с Perfect CSI. В таблице представлены значения разницы в [дБ] между рассматриваемыми нейросетевыми приёмниками и идеальным приёмником для пяти различных типов каналов CDL (A-E) при двух фиксированных значениях BLER:  $10^{-1}$  и  $10^{-2}$ . Каждый столбец соответствует определённой архитектуре: базовый нейросетевой приёмник с 4 остаточными блоками, улучшенная версия с 6 остаточными блоками и предложенная модификация с 4 CBAM Residual Blocks. Зелёным цветом выделены наилучшие результаты (минимальное отклонение от идеального приёмника), красным — наихудшие результаты (максимальное отклонение). Анализ данных демонстрирует, что архитектура с CBAM Residual Blocks последовательно показывает наилучшую производительность среди всех типов каналов и значений BLER, что подтверждает эффективность механизма внимания для задач детектирования в OFDM-системах.

В качестве экспериментов проведено сравнение модифицированного нейросетевого приёмника с тремя ранее рассмотренными моделями: Perfect CSI, LS estimation и нейросетевым приёмником от NVIDIA. Сравнение проведено на всех видах CDL каналов: A , B , C , D , E .

В CDL каналах модели A, B и C относятся к условиям вне зоны прямой видимости (англ. Non-Line-of-Sight, NLOS), а D и E — к условиям в пределах прямой видимости (англ. Line-of-Sight, LOS). NLOS подразумевает, что сигнал достигает приемника через отражения, дифракцию или рассеивание из-за препятствий, таких как здания, деревья или другие объекты. NLOS-каналы (A, B, C) характеризуются более высокими потерями на трассе, большей задержкой распространения и выраженным многолучевым эффектом, что приводит к межсимвольной интерференции. В то же время LOS означает, что между передатчиком и приемником существует прямая видимость, без физических препятствий. LOS-каналы (D, E) обладают более стабильными характеристиками, меньшими задержками и преобладанием основного луча, что улучшает качество сигнала.

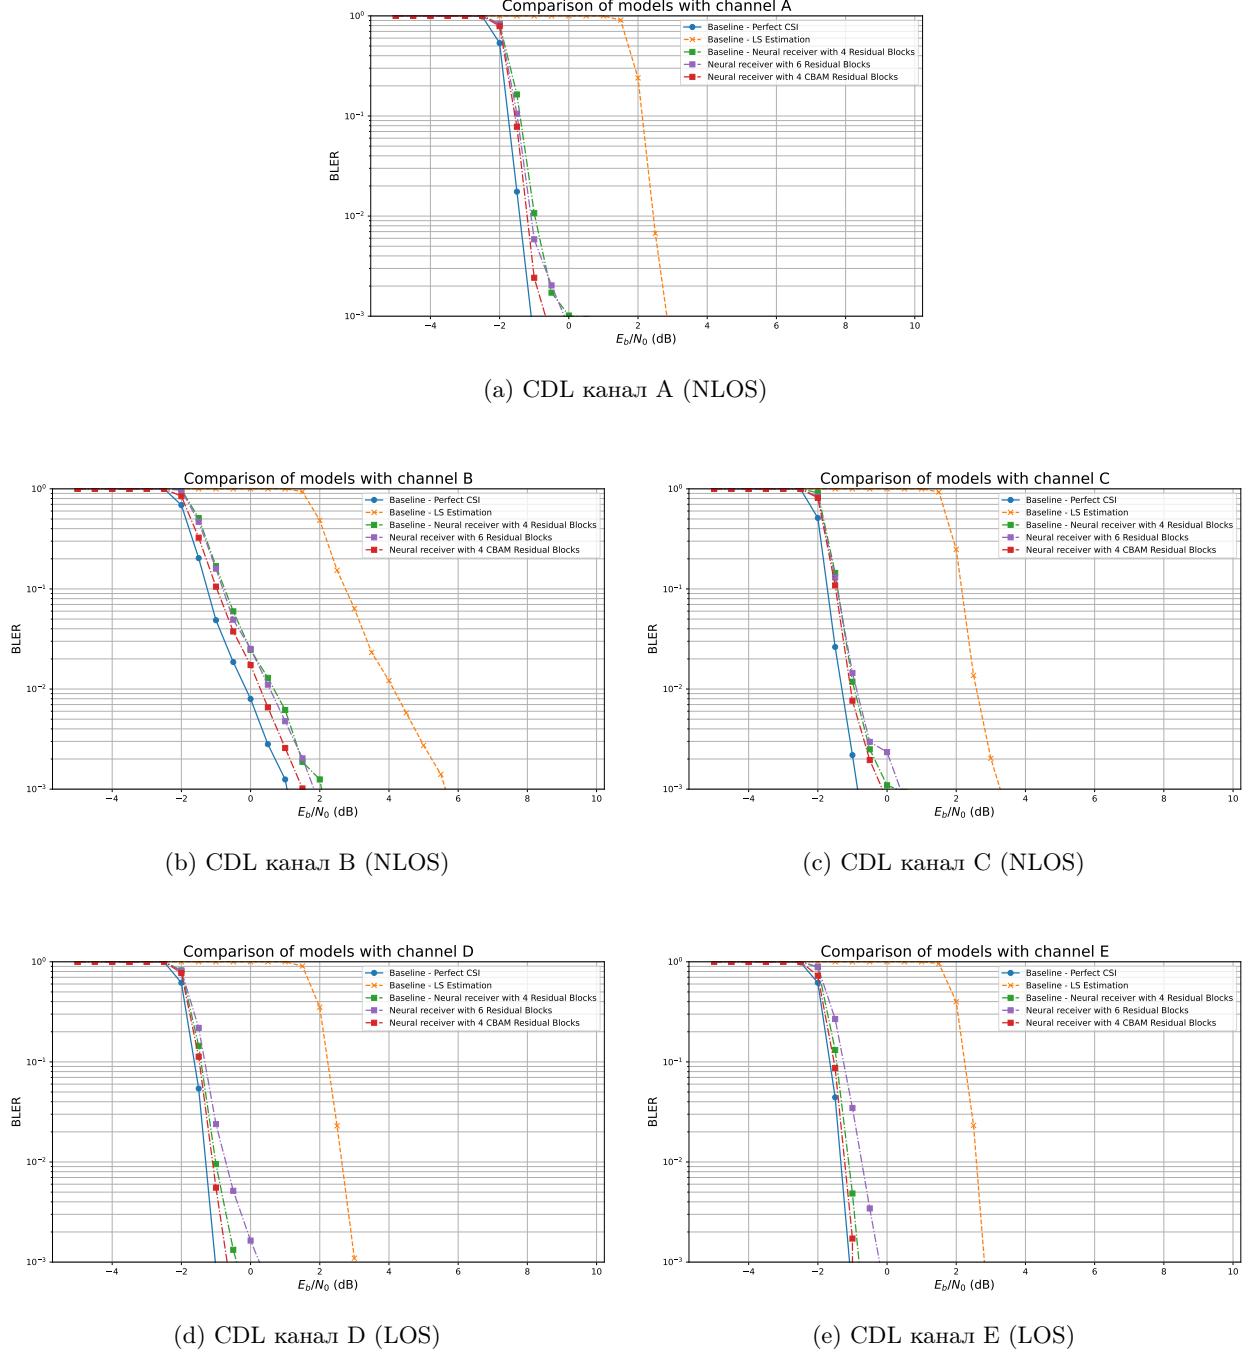


Рис. 3: Сравнение производительности различных приёмных систем на пяти типах CDL каналов. На каждом графике представлены пять кривых, отображающих зависимость BLER от отношения сигнал/шум  $E_b/N_0$  [дБ] для: эталонного приёмника с Perfect CSI (идеальная информация о канале), классического приёмника с LS-оценкой канала, нейросетевого приёмника с 4 остаточными блоками, нейросетевого приёмника с 6 остаточными блоками и предложенного нейросетевого приёмника с 4 CBAM Residual Blocks. Графики демонстрируют, что архитектура с CBAM Residual Blocks последовательно приближается к производительности идеального приёмника, превосходя как классические методы, так и базовые нейросетевые архитектуры. Логарифмическая шкала по оси ординат позволяет наглядно оценить экспоненциальное снижение вероятности ошибок при улучшении условий приёма.

В итоге, из графиков и таблицы сравнения приёмников на каждой модели CDL канала можно заметить следующее:

1. Простой подход с увеличением числа Residual блоков привёл к незначительным улучшениям нейросетевого приёмника на моделях A и B (улучшения до 0,138 [дБ]), а на остальных моделях CDL канала продемонстрированы ухудшения показателей (ухудшение до 0,380 [дБ]).
2. Предложенный метод модификации нейросетевого приёмника оказался действительно рабочим и продемонстрировал значимые результаты на всех моделях CDL канала: заметен явный прирост в качестве в сравнении с исходным нейросетевым приёмником от NVIDIA (улучшение на NLOS каналах в диапазоне от 0.069 [дБ] до 0.368 [дБ] и улучшение на LOS каналах в диапазоне от 0.034 [дБ] до 0.103 [дБ]), а на CDL-E кривая модифицированной модели почти аппроксимирует кривую идеального приёмника с разницей на 0.138 [дБ].

## 6 Заключение

В статье проведено исследование применения методов глубокого обучения для оптимизации PHY Layer в системах связи 5G. Рассмотрены как классические подходы к обработке сигналов (LS channel estimator, LMMSE equalizer), так и современный нейросетевой приёмник на основе остаточных свёрточных блоков. Показано, что базовая нейросетевая архитектура демонстрирует значительное превосходство над традиционными методами, приближаясь к эталонному сценарию с полным знанием канала (Perfect CSI).

Основной вклад работы — разработка модифицированного нейросетевого приёмника, усиленного механизмом внимания CBAM. Экспериментальная оценка на наборе стандартизованных моделей каналов CDL подтвердила эффективность предложенного подхода. Модифицированный приёмник показал устойчивое улучшение помехоустойчивости по сравнению с базовой нейросетевой архитектурой, особенно в сложных условиях NLOS-распространения.

Практическая значимость исследования заключается в демонстрации потенциала механизмов внимания для создания более эффективных и адаптивных систем приёма данных. Предложенное решение открывает пути для дальнейшей оптимизации нейросетевых алгоритмов в целях повышения спектральной эффективности и надёжности беспроводных сетей.

## Список литературы

- Mohamed Badr, Pascal Leduc, and François Gagnon. Lmmse channel estimation in ofdm context: a review. *IET Signal Processing*, 13(2):129–135, 2019.
- K. Praveen Bagadi and Susmita Das. Mimo-ofdm channel estimation using pilot carries. *International Journal of Computer Applications*, 2(3):81–86, 2010.
- Emil Björnson, Michail Matthaiou, and Mérouane Debbah. Achievable rate of rician large-scale mimo channels with transceiver hardware impairments. arXiv preprint arXiv:1507.04244, 2015.
- Giuseppe Caire, Alex Alvarado, and Hideki Yagi. Achievable rates for probabilistic shaping. arXiv preprint arXiv:1707.01134, 2017.
- A. Gansekoele, A. Balatsoukas-Stimming, T. Brusse, M. Hoogendoorn, S. Bhulai, and R. van der Mei. Joint demapping of qam and apsk constellations using machine learning. *IEEE Open Journal of the Communications Society*, 6:1695–1710, 2025.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. pages 770–778, 2016.
- Jakob Hoydis, Sebastian Cammerer, Fayçal Ait Aoudia, Avinash Vem, Nikolaus Binder, Guillermo Marcus, and Alexander Keller. Sionna RT: A modular Python library for next-generation physical layer research. <https://nvlabs.github.io/sionna/>. Accessed: 2024-06-15.
- Jakob Hoydis, Sebastian Cammerer, and Fayçal Ait Aoudia. Neural receiver for OFDM SIMO systems. [https://nvlabs.github.io/sionna/phy/tutorials/Neural\\_Receiver.html](https://nvlabs.github.io/sionna/phy/tutorials/Neural_Receiver.html), 2023. Accessed: 2024-06-15.
- Kfir M. Levis, Idan Liani, Idan Gurevitz, and Simon Litsyn. Deeprx: Fully convolutional deep learning receiver. arXiv preprint arXiv:2005.01494, 2020a.
- Kfir M. Levis, Idan Liani, Idan Gurevitz, and Simon Litsyn. End-to-end learning for ofdm: From neural receivers to pilotless communication. arXiv preprint arXiv:2009.05261, 2020b.
- T. T. Bao Nguyen, T. T. Nguyen, and H. Lee. Efficient qc-ldpc encoder for 5g new radio. *Electronics*, 8(6):668, 2019.
- T. T. Bao Nguyen, T. T. Nguyen, and H. Lee. Low-complexity high-throughput qc-ldpc decoder for 5g new radio wireless communication. *Electronics*, 10(4):516, 2021.
- A. M. Pessoa, B. Sokal, C. F. M. E. Silva, T. F. Maciel, A. L. F. de Almeida, and F. R. P. Cavalcanti. A cdl-based channel model with dual-polarized antennas for 5g mimo systems in rural remote areas. *IEEE Access*, 8:174248–174263, 2020.
- Chintan R. Shah. Performance and comparative analysis of siso, simo, miso, mimo. *International Journal of Wireless Communication and Simulation*, 9(1):1–14, 2017.
- Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module. Proceedings of the European conference on computer vision (ECCV), pages 3–19, 2018.